

Reto 2

Planteamiento y análisis de un problema de Clasificación

1 Introducción

En este documento se presenta un problema de Clasificación Binaria cuya solución y análisis debe presentarse través de un informe.

2 Contexto del problema

Dentro de las terapias alternativas para el tratamiento del cáncer, la **Hadronterapia** se presenta como una de las opciones más prometedoras [1]. En el contexto de la radioterapia, el uso de partículas pesadas cargadas -como protones y otros iones pesados, por ejemplo, el carbono- permite un mayor control del haz sobre la región de interés. Además, la naturaleza de su interacción con materiales biológicos hace posible que la máxima pérdida de energía y la mayor densidad de ionización ocurran al final de su trayectoria, fenómeno conocido como pico de Bragg [2] [3]. Esto permite depositar la dosis máxima a mayor profundidad en el tejido, concentrando el impacto directamente sobre el tumor, atacando con mayor eficacia las células afectadas y mejorando sustancialmente la respuesta del organismo al tratamiento [3].

Actualmente, los sistemas de hadronterapia incluyen un acelerador de partículas - compuesto por una fuente de iones, sincrotrón y línea de transporte- acoplado a un sistema de distribución denominado *gantry*, que permite focalizar los hadrones sobre la región de interés desde múltiples ángulos [2]. La figura 1 muestra un ejemplo de este tipo de dispositivos.

La principal desventaja de esta alternativa es su elevado costo. Debido a la alta rigidez magnética de los protones y de los iones de carbono, se requieren aceleradores de grandes dimensiones para producir los haces con la energía adecuada [2].




Figure 1: Gantry isocéntrico para protones diseñado por Mitsubishi (izquierda). Diseño de gantry isocéntrico para iones de carbono (derecha) [2]

Suponga ahora que se ha desarrollado un nuevo proceso de bajo costo para generar haces de protones, pero que produce también rayos gamma residuales de alta energía. El objetivo de este reto consiste en implementar un modelo de red neuronal (ANN) capaz de clasificar el haz generado como **hadrón** o

gamma, a partir de la información recopilada por un detector. Esta clasificación permitiría seleccionar únicamente los haces adecuados antes de su transporte al gantry para la irradiación al paciente. De este modo, podemos controlar con mayor precisión el tipo de radiación administrada, garantizando así la seguridad y eficacia del procedimiento.

2.1 Requerimientos:

En este reto, el modelo de red neuronal deberá incluir, como mínimo, los siguientes elementos estructurales:

- **Capa de entrada:** Debe recibir las variables o características extraídas por el detector del haz. El número de neuronas de entrada debe corresponder al número de características disponibles en el conjunto de datos.
- **Capas ocultas:** Al menos una capa oculta completamente conectada. Deben usar funciones de activación no lineales, como ReLU. Pueden incluir más de una capa oculta para mejorar la capacidad de aprendizaje.
- **Capa de salida:** Debe realizarse una clasificación binaria entre las categorías **hadrón** o **gamma**. Debe incluir una función de salida adecuada para la tarea.
- **Función de pérdida:** Debe emplearse una función apropiada para clasificación binaria.
- **Optimizador:** Uso obligatorio de un algoritmo de optimización. Su elección hace parte de los hiperparámetros del modelo.
- **Proceso de entrenamiento:** Se debe dividir el conjunto de datos proporcionado en un conjunto de entrenamiento y de validación teniendo en cuenta que se ha separado previamente el 20% del total como conjunto de prueba. Asimismo se debe establecer un número específico de épocas de entrenamiento y tamaño de *batch*.
- **Métricas de evaluación:** Puede contemplar todas las que considere adecuadas para la evaluación de la tarea. Debe incluirse la matriz de confusión y la sensibilidad (*recall*) entre las elegidas.
- **Framework:** La implementación debe desarrollarse utilizando el módulo **Keras** de la librería **Tensorflow** únicamente. Pueden apoyarse en las demás librerías de Python para Machine Learning que se abordaron a lo largo del curso: *Numpy*, *Pandas*, *Matplotlib*, *Scikit-Learn*, *Scipy*.
No se acepta el uso de ninguna otra librería para Deep Learning o Machine Learning.
- **Arquitectura:** No se acepta el uso de modelos pre-entrenados ni estrategias de *Transfer Learning*. El modelo debe desarrollarse completamente desde cero con las herramientas que proporciona **Keras**.

Adicionalmente, pueden incluir técnicas básicas de regularización como *Dropout* y *Early Stopping* y estrategias de selección de modelo como *GridSearch*.

2.2 Datos y entrenamiento del modelo:

Para el entrenamiento del modelo se dispone de datos reales. Para el desarrollo del reto tendrán a su disposición tres archivos:

- *hadron_train.csv*: Conjunto de datos destinado al entrenamiento y la validación del modelo. Las categorías se han representado como 1 (*hadrón*) y 0 (*gamma*). Cada grupo debe determinar los porcentajes de distribución entre los conjuntos de entrenamiento y validación.

- *hadron_test.csv*: Conjunto de datos que contiene únicamente los valores de las características.
- *helpers.py*: Contiene la función ***check_requirements()*** que permite verificar que el archivo CSV de solución cumple los requerimientos solicitados.

2.3 Modelo final:

Para determinar el modelo final, se recomienda evaluar múltiples arquitecturas de red neuronal, empleando distintas combinaciones de hiperparámetros. La selección debe realizarse con base en el análisis comparativo de las curvas de aprendizaje y el desempeño obtenido en las métricas de evaluación.

Una vez identificado el modelo con mejor rendimiento, este deberá utilizarse para predecir las categorías asociadas a los datos contenidos en el archivo *hadron_test.csv*.

La calificación de este reto dependerá directamente de la precisión del modelo al clasificar correctamente la categoría a la que pertenece cada haz en dicho conjunto de datos.

3 Contenido de la entrega

Cada grupo de trabajo tiene que entregar dos documentos:

Informe: En un archivo de **Jupyter Notebook** se debe documentar detalladamente el proceso seguido para llegar al modelo final. El informe debe incluir los siguientes componentes:

1. Explicación del problema general con sus palabras.
2. Definición de todos los componentes del problema de Clasificación, donde se justifique su planteamiento.
3. Descripción de la implementación del código utilizado.
4. Fase de entrenamiento y validación del modelo. En esta sección se recomienda incluir tablas y/o gráficas comparando el rendimiento de los diferentes modelos así como el análisis de sus curvas de aprendizaje.
5. Identificación del modelo final, cuya arquitectura e hiperparámetros deben ser indicados claramente en el informe.
6. Finalmente incluya un análisis del modelo final desde el punto de vista del contexto del problema.

Archivo de datos: Archivo en formato *CSV* de nombre *predictions* con :

1. La primeras seis columnas deben identificarse con el nombre específico de cada característica y contener los valores consignados en el archivo *hadron_test.csv* que utilizó para hacer las predicciones del modelo final.
2. La séptima columna debe identificarse con el nombre **prediction** y debe contener las clases predichas por el modelo final.

El archivo **predictions.csv** creado debe tener 2676 predicciones. **En caso de que este archivo no cumpla con las especificaciones dadas la nota asignada al laboratorio será 1.0 directamente sin posibilidad de entrega posterior a la fecha final de entrega.** Para ello, verifique que este archivo tenga el formato correcto, los nombres de las columnas indicados y el número específico de predicciones solicitado haciendo uso de la función ***check_requirements*** del módulo ***helpers.py***.

4 Rúbrica de calificación

Para la calificación de este reto se tendrán en cuenta los siguientes aspectos:

- Estructura del informe evaluada según los siguientes criterios (50%):
 - Redacción y organización del informe, buenas prácticas de programación (5%).
 - Claridad y exactitud de la formulación matemática (15%). **Las ecuaciones tienen que estar escritas en formato Latex.**
 - Profundidad y detalle en el análisis del modelo (15%).
 - Presentación clara y justificada de un modelo final que cumpla con los requerimientos (5%).
 - Profundidad en el análisis desde el punto de vista del contexto del problema (10%).
- Rendimiento del modelo final (50%): Se calcula el *recall* del modelo final con los datos del archivo *predictions.csv*. Se asignará 5.0 sobre este porcentaje de nota al grupo con el *recall* más grande (mejor generalización) y una nota de 0.5 al grupo con la métrica más pequeña (peor generalización). La nota del resto de los grupos de todas las secciones de laboratorio se calculará haciendo uso de la siguiente ecuación:

$$C = \frac{4.5}{\max - \min} \cdot (\text{Recall} - \min) + 0.5$$

Donde *max* y *min* son los valores de la métrica *recall* más grande y más pequeño hallados en todas las secciones del curso y **Recall** corresponde al valor calculado para su modelo.

NOTA: Toda entrega con un Recall inferior a 0.7 o un informe en el que las ecuaciones no esten escritas en formato Latex no se tendrá en cuenta y su calificación del reto será 1.0 directamente.

5 Responsabilidades del estudiante

Esta actividad debe reflejar el trabajo en el curso por cada grupo de estudiantes que se conformó al inicio del semestre para los laboratorios y no el de dos o más grupos. En este sentido, cualquier sospecha de fraude por parte de dos o más grupos de trabajo de todas las secciones de laboratorio, será reportada al Comité de Asuntos Disciplinarios (CISO).

References

- [1] CERN. What is hadron therapy?, 2026.
- [2] E. Vicente S. España J. Cal-González J. M. Udías E. Herranz, J. L. Herraiz. Hadronterapia. *I Encuentro Complutense para la Divulgación en Física Nuclear y de Partículas*, 2008.
- [3] Valable S. Laurent C. Haghdoust S. Pérès E. A.-Bernaudin M. Sichel F. Lesueur P. Césaire M. Petit E. Ferré A. E. Saintigny Y. Skog S. Tudor M. Gérard M. Thureau S. Habrand J. L. Balosso J. Chevalier F Thariat, J. Hadrontherapy interactions in molecular and cellular biology. *International journal of molecular sciences*, 2019.